

Family of Five Genome Dataset

가족 유전체 분석 최종 보고서

이 보고서는 23andMe raw genotype 데이터 5종(Father / Mother / Child 1 / Child 2 / Child 3)을 대상으로, 데이터사전 작성부터 전처리, 시각화, 트리오 멘델 검증까지의 전 과정을 정리한 결과물입니다. 미성년 자녀가 포함된 데이터라는 점을 고려해 질병·인지능력 관련 SNP은 분석에서 제외했습니다.

작성 정보

대상 파일 | Father, Mother, Child 1, Child 2, Child 3 (23andMe raw genotype)

작성일 | 2026-08-04

작성 도구 | Python(pandas) 전처리 · matplotlib 시각화 · docx 자동 생성

CONTENTS

목차

1. 분석 질문	3
2. 데이터사전	4
3. 전처리로그	8
4. 시각화	9
5. 인사이트	13
6. 다루지 않은 것들	15
7. 참고 자료	15

ANALYSIS QUESTIONS

1. 분석 질문

이번 분석은 다음 4가지 질문을 중심으로 진행했습니다.

- ① **출산지(조상 기원):** 부모의 조상 기원(ancestry) 마커는 서로 얼마나 일치하며, 자녀들의 유전형은 부모의 대립유전자 조합으로 설명되는가?
- ② **특정 형질을 결정하는 유전자:** 부모의 유전형을 바탕으로 자녀의 특정 형질(머리색, 체질, 미각 등)이 멘델의 유전 법칙에 따라 어떻게 유전되는가?
- ③ **서구 데이터셋과의 비교:** 이 가족의 유전적 특성은 서구 중심의 GWAS 데이터베이스와 비교했을 때 얼마나 일치하며, 인구집단 차이로 인한 예측 정확도(이식성, Transferability)에는 어떤 한계가 있는가?
- ④ **데이터셋의 특이한 점:** 실제 혈연관계가 확인된 부모-자녀 2세대 가족 유전체 데이터라는 점에서 어떤 연구적 가치와 차별성을 가지는가?

아래 2~5장은 이 질문들에 답하기 위해 실제로 수행한 데이터 처리·시각화·분석 결과입니다.

2. 데이터사전

데이터의 열 이름, 의미, 단위, 데이터형, 결측·이상 기준을 먼저 정리한 뒤, 5개 파일(아빠/엄마/자녀1/자녀2/자녀3) 각각에 대해 SNP 총 개수, 염색체별 분포, 유전자형 구성, 결측치(노콜) 비율, 성염색체·미토콘드리아 데이터 유무를 확인했습니다.

2-1. 컬럼(변수) 사전

5개 파일은 모두 동일하게 4개 컬럼으로 구성되어 있습니다.

컬럼명	의미	데이터형	값 범위 / 단위
rsid	SNP을 식별하는 고유 ID (Reference SNP ID). 일부는 공개 rsID가 아직 없는 23andMe 내부 연구용 ID(i로 시작)	문자열(string)	예: rs12913832, i706946 등 — 파일 내 고유값
chromosome	이 SNP이 위치한 염색체	문자열/범주형(category)	1~22, X, Y, MT (총 25개 범주)
position	해당 염색체 상에서 SNP의 물리적 위치(염기서열 좌표)	정수 (bp, base pair)	1 이상의 정수, 염색체별 길이 이내
genotype	실제 관측된 유전자형(부모로부터 물려받은 대립유전자 조합)	문자열	2문자(예 AG: 이형/동형접합), 1문자(반접합, X/Y/MT), '-'/'00'(no-call), D/I 포함(indel)

2-2. 행x열 / 중복 행 점검

구성원	행 x 열	완전 중복행(행 전체 동일)	rsid 중복	동일(염색체, 위치) 중복 마커 수
Father	601,802 x 4	0	0	3,596
Mother	601,802 x 4	0	0	3,596
Child 1	601,802 x 4	0	0	3,596
Child 2	631,983 x 4	0	0	2,459
Child 3	631,983 x 4	0	0	2,459

완전 중복행·rsid 중복: 행 전체가 동일한 완전 중복행과 rsid 자체가 중복된 행은 5개 파일 모두 0건으로, 각 SNP이 정확히 한 번씩만 기록되어 있습니다.

(염색체, 위치) 중복: 반면 같은 염색체·같은 위치를 서로 다른 rsid(마커) 두 개 이상이 가리키는 경우는 다수 발견되었습니다 — Father·Mother·Child 1에서 3,596건, Child 2·Child 3에서 2,459건입니다. 예를 들어 1번 염색체 2,526,746 위치는 공개 rsID인 rs3748816과 23andMe 내부 연구용 ID인 i6059967이 같은 위치·같은 유전형(AG)을 중복 보고합니다. 이는 데이터 오류라기보다 23andMe 칩이 같은 물리적 위치를 두 개의 프로브(공개 rsID + 내부 ID)로 동시에 측정한 결과이며, 두 그룹 모두에서 미토콘드리아(MT) 위치가 중복의 절반 이상을 차지합니다 — MT 게놈은 16.5kb로 매우 짧아 같은 위치가 여러 마커로 중복 프로브될 가능성이 상대적으로 높기 때문입니다.

2-3. 이상치(이상 기준) 점검

이상 기준은 다음과 같이 정의했습니다: chromosome이 1~22·X·Y·MT 범주를 벗어나는 값, position이 결측이거나 0 이하인 값, genotype이 허용 패턴(2문자 ACGT 조합·1문자 반접합·no-call 코드·indel 코드) 밖의 값.

구성원	chromosome 범위 이탈	position 이상(결측·0 이하)	genotype 패턴 이탈
Father	0	0	0
Mother	0	0	0
Child 1	0	0	0
Child 2	0	0	0
Child 3	0	0	0

세 기준 모두 5개 파일 전부에서 0건입니다 — 원자료 자체의 값 형식은 매우 깨끗하며, 위 2-2에서 확인한 (염색체, 위치) 중복을 제외하면 별도의 값 이상치는 발견되지 않았습니다.

2-4. 결측 셀 점검

여기서 "결측 셀"은 셀 자체가 완전히 비어 있는(NaN) 경우를 뜻하며, genotype이 '--/00'으로 채워진 "노콜(no-call)"과는 구분됩니다 — 노콜은 셀에 값이 존재하지만 그 값이 "관독 실패"를 의미하는 경우입니다.

구성원	rsid 결측	chromosome 결측	position 결측	genotype 결측	결측 셀 비율
Father	0	0	0	0	0.0000%
Mother	0	0	0	0	0.0000%
Child 1	0	0	0	0	0.0000%
Child 2	0	0	0	0	0.0000%
Child 3	0	0	0	0	0.0000%

네 컬럼 모두 진짜 결측 셀(NaN)은 5개 파일 전부에서 0건입니다 — 즉 원자료의 모든 행에 rsid·chromosome·position·genotype 값이 형식상으로는 항상 채워져 있습니다. 실질적인 "결측"은 genotype 값이 관독 실패를 나타내는 no-call 코드('--' 등)인 경우이며, 이 비율은 아래 2-5 표의 "노콜" 컬럼에서 확인할 수 있습니다 (Father 1.10% ~ Child 3 2.54%).

2-5. 구성원별 데이터사전 요약 (SNP 분포·유전자형 구성)

구성원	총 SNP	1-22번	X	Y(유효관독)	MT	동형접합	이형접합	반접합	노콜	성별추정
Father	601,802	574,927	19,478	1,293/2,302 (56.2%)	5,095	66.82%	27.42%	4.00%	1.10%	남성
Mother	601,802	574,927	19,478	0/2,302 (0.0%)	5,095	68.93%	27.68%	0.80%	1.94%	여성
Child 1	601,802	574,927	19,478	1,298/2,302 (56.4%)	5,095	66.64%	27.20%	3.97%	1.54%	남성
Child 2	631,983	608,182	16,143	3,134/3,501 (89.5%)	4,157	77.74%	15.73%	3.46%	2.32%	남성
Child 3	631,983	608,182	16,143	3,134/3,501 (89.5%)	4,157	77.08%	16.24%	3.39%	2.54%	남성

칩 버전 차이: Father·Mother·Child 1은 동일한 23andMe 칩(총 601,802 SNP)을 사용했고, Child 2·Child 3는 더 신형 칩(총 631,983 SNP)을 사용한 것으로 보입니다. 두 그룹 간 이형접합 비율이 체계적으로 다른 것(27% 내외 vs 16% 내외)은 생물학적 차이가 아니라 칩에 포함된 SNP 구성 차이일 가능성이 높습니다 — 이후 인사이트 해석에서 이

점을 계속 고려했습니다.

성염색체/MT 존재 여부: 5명 모두 X, Y, MT 데이터가 존재합니다. 다만 23andMe 칩은 생물학적 성별과 무관하게 Y 염색체 프로브 위치 자체는 항상 포함하므로, 단순히 Y행의 존재 여부가 아니라 그 위치에서 "유효 판독(no-call이 아닌 콜)" 비율로 성별을 추정해야 합니다. 이 기준으로 보면 Mother는 Y 위치 2,302개 전부가 no-call(유효판독 0%)로 여성과 일치하고, 나머지 4명은 Y 유효판독률이 56~90%로 남성과 일치합니다 — 미토콘드리아(MT) 데이터는 5명 모두 존재해 모계 유전 분석(하플로그룹 추정 등)이 원리상 가능하지만, 이번 분석에서는 다루지 않았습니다.

3. 전처리로그

아래 단계를 5개 파일에 동일하게 적용했습니다.

- ① **인코딩/헤더 정리**: 각 파일 상단의 '#'로 시작하는 주석 헤더를 `comment='#'` 옵션으로 건너뛰고, `rsid/chromosome/position/genotype` 4개 컬럼으로 로드했습니다.
- ② **타입 변환**: `chromosome`은 문자열(카테고리)로 유지해 `X·Y·MT`를 숫자 엄색체와 분리 처리했고, `position`은 숫자형(`Int64`)으로 변환했습니다.
- ③ **결측/노콜 플래그**: `genotype`이 '-' 등으로 표시된 행을 삭제하지 않고 `is_nocall` 플래그 컬럼으로 표시해, 필요할 때만 걸러낼 수 있게 했습니다. 같은 방식으로 `is_indel`(삽입/결실), `is_biallelic`, `is_hemizygous` 플래그도 만들었습니다.
- ④ **이형접합 파생 컬럼**: 두 대립유전자 문자가 서로 다른 경우를 `is_heterozygous=True`로 표시하는 파생 컬럼을 추가했습니다.
- ⑤ **5개 파일 rsid 기준 병합**: 가족 구성원 간 비교를 하려면 이 단계가 핵심입니다. 5개 파일의 `rsid`를 합집합 기준으로 병합해 1,117,586개 행(`rsid`) × 구성원별 유전형 컬럼(`gt_Father`, `gt_Mother`, `gt_Child1`, `gt_Child2`, `gt_Child3`)으로 구성된 하나의 표를 만들었습니다. 5명 전원에게 공통으로 존재하는 `rsid`(완전 교집합)는 116,199개였습니다 — 칩 버전이 다른 `Child 2·3` 때문에 완전 교집합이 개별 파일 크기보다 훨씬 작습니다. 이후 시각화·인사이트 단계에서는 분석 목적에 따라 완전 교집합 또는 쌍별(`pairwise`) 교집합을 선택적으로 사용했습니다.

4. 시각화

4-1. 염색체별 SNP 개수 (구성원별 비교)




그림 1. 염색체별 SNP 개수 — 구성원 5명 비교 (1~22, X, Y, MT 순)

다섯 명 모두 1번 염색체에서 SNP이 가장 많고 21·22·Y·MT에서 가장 적은, 염색체 길이에 비례하는 공통 패턴을 보입니다. Child 2·Child 3의 막대가 전반적으로 더 긴 것은 앞서 데이터사전에서 확인한 신형 칩(더 많은 SNP 포함) 때문입니다.

4-2. 이형접합 비율 비교 (아빠/엄마/자녀1/2/3)




그림 2. 구성원별 이형접합 비율(%) — accent 색은 Child 2·3(신형 칩 그룹) 강조

Father·Mother·Child 1은 27% 내외로 비슷한 반면, Child 2·Child 3는 16% 내외로 뚜렷이 낮습니다. 이 차이는 실제 유전적 특성이거나보다 칩 설계 차이(신형 칩에 상대적으로 동형접합 SNP이 더 많이 포함됨)를 반영할 가능성이 큽니다.

4-3. 가족 구성원 간 유전자형 일치율 히트맵




그림 3. 쌍별(rsid 교집합 기준) 유전자형 완전 일치율(%)

	Father	Mother	Child 1	Child 2	Child 3
Father	—	58.8%	70.9%	68.0%	67.9%
Mother	58.8%	—	70.7%	68.2%	68.1%
Child 1	70.9%	70.7%	—	70.5%	72.7%
Child 2	68.0%	68.2%	70.5%	—	85.7%
Child 3	67.9%	68.1%	72.7%	85.7%	—

모든 쌍이 58~73% 구간에 있는 가운데, Child 2-Child 3 쌍만 85.7%로 눈에 띄게 높습니다. 부모-자녀(Father/Mother 대 자녀 3명)는 68~73%, 부모끼리(Father-Mother)는 58.8%로 가장 낮습니다 — 혈연관계가 없는 두 성인의 일치율이 가장 낮고, 형제자매 중에서도 Child 2·3가 유독 가깝다는 패턴이 일관되게 나타납니다.

4-4. 특정 염색체의 position별 genotype 분포 (21번 염색체, 14.5-19.5Mb 구간)




그림 4. 21번 염색체 일부 구간 — position별 접합 유형 분포 (구성원별 소패널)

21번 염색체의 5Mb 구간을 확대해 각 position에서의 접합 유형(동형접합/이형접합/반접합/미판독)을 구성원별로 나란히 표시했습니다. 다섯 명 모두 약 15.2~15.4Mb 부근에 미판독(no-call)이 몰려 있는 공통 구간이 관찰되는데, 이는 특정 개인의 문제가 아니라 이 위치의 프로브 자체가 판독 품질이 낮은 구간일 가능성을 시사합니다.

4-5. 형제자매 3명 간 유사도 클러스터링(덴드로그램)




그림 5. Child 1·2·3 간 유전형 일치율 기반 계층적 군집화

유전자형 일치율(그림 3)을 거리로 변환해 계층적 군집화를 수행한 결과, Child 2와 Child 3가 가장 먼저(거리 약 14.3) 하나의 군집으로 묶이고, Child 1은 상대적으로 더 먼 거리(약 28.3)에서 뒤늦게 합류합니다 — 형제자매 3명이 균등하게 비슷한 것이 아니라, Child 2·3 두 명이 서로 더 가깝다는 것을 시각적으로 보여줍니다.




그림 5-1(참고). 부모 포함 5명 전체 군집화 — Father·Mother가 각각 가장 늦게 합류해 자녀 그룹과 뚜렷이 구분됨

5. 인사이드

5-1. 멘델 유전 법칙 검증 (트리오 멘델 오류율)

트리오 데이터에서 가장 대표적인 분석입니다. 아빠와 엄마의 유전형 조합으로 설명 가능한지 자녀별로 검증했습니다(예: 아빠 AA, 엄마 GG면 자녀는 반드시 AG여야 함).

자녀	비교 가능 SNP	위반 건수	오류율
Child 1	556,904	107	0.019%
Child 2	106,021	11	0.010%
Child 3	106,126	16	0.015%

세 자녀 모두 오류율이 0.02% 미만으로 매우 낮아, 통상적인 판독 오차(칩 노이즈) 수준 안에서 Father·Mother와 생물학적 부모-자녀 관계가 일치함을 확인했습니다. Child 2·Child 3의 비교 가능 SNP 수(약 106,000개)가 Child 1(약 557,000개)보다 훨씬 적은 것은 앞서 확인한 칩 버전 차이 때문에 Father/Mother와 겹치는 rsid 수 자체가 더 작기 때문입니다.

5-2. 부모 기원 추정 (어느 대립유전자가 아빠/엄마 쪽인지)

일부 SNP에서만 가능한 분석입니다. 아빠와 엄마가 모두 동형접합이면서 서로 다른 대립유전자를 가진 경우("완전 정보(fully informative)" SNP), 자녀가 물려받은 대립유전자가 아빠 쪽인지 엄마 쪽인지 확실하게 구분할 수 있습니다. 부모 유전형을 비교할 수 있는 SNP 560,545개 중 32,436개(5.79%)가 이 조건을 만족했습니다.

rsid	형질	Father	Mother	Child 1	Child 2	Child 3
rs1815739	ACTN3(근섬유 유형)	CT	CT	CT	TT	CC
rs713598	TAS2R38(쓴맛 민감도)	CG	CG	CC	CG	CG
rs762551	CYP1A2(카페인 대사)	AC	AA	AA	AA	AC

ACTN3(rs1815739)은 부모가 둘 다 이형접합(CT)이라 완전 정보 SNP는 아니지만, 자녀 세 명이 CT/TT/CC로 갈리는 전형적인 멘델 분리를 보여줍니다. TAS2R38(rs713598)과 CYP1A2(rs762551)는 실제로 부모 중 한쪽에서 물려받은 대립유전자를 특정할 수 있는 예시입니다 — 예를 들어 CYP1A2에서 Father(AC)·Mother(AA) 조합일 때 Child 3(AC)이 물려받은 C 대립유전자는 반드시 Father 쪽에서 온 것으로 특정됩니다.

5-3. 형제자매 간 유전적 유사도

자녀 세 명이 서로 얼마나 비슷한지는 앞의 그림 3(일치율 히트맵)과 그림 5(텐드로그램)에서 이미 확인했습니다. Child 2-Child 3 일치율(85.7%)은 Child 1과 나머지 두 명 사이의 일치율(70.5%, 72.7%)보다 뚜렷하게 높습니다. 일반적인 전형매(full sibling) 사이의 기대 공유 비율보다 높은 수치로, 데이터만 놓고 보면 이란정보보다 더 가까운 관계(예: 일란성 쌍둥이)의 가능성과도 부합하는 패턴입니다. 다만 이 데이터셋만으로 쌍둥이 여부를 단정할 근거는 없으며, 칩 버전이 같다는 점(둘 다 신형 칩)이 일치율을 다소 높이는 방향으로 작용했을 가능성도 배제할 수 없습니다.

5-4. 이형접합도(heterozygosity) 비교

구성원	이형접합 비율	노콜 비율
Father	27.42%	1.10%
Mother	27.68%	1.94%
Child 1	27.20%	1.54%
Child 2	15.73%	2.32%
Child 3	16.24%	2.54%

Father·Mother·Child 1(같은 구형 칩)은 27% 내외로 유사하고, Child 2·Child 3(신형 칩)은 16% 내외로 두 그룹이 뚜렷이 나뉩니다. 이 차이는 칩에 포함된 SNP 선정 기준이 다르기 때문일 가능성이 크며, 실제 개인의 생물학적 이형접합도 차이로 해석하는 것은 부적절합니다 — 같은 칩을 쓴 세 사람(Father/Mother/Child 1) 사이의 27.2~27.7% 범위 내 차이 정도가 실제 개인차에 가깝다고 보는 것이 합리적입니다.

OUT OF SCOPE

6. 다루지 않은 것들

암·질병 발병 여부, 지능·인지능력, 비만·체질 예측 등은 이번 분석에서 다루지 않았습니다. 특히 이 데이터셋은 미성년으로 추정되는 자녀 3명을 포함하고 있어, 아직 스스로 검사에 동의할 수 없는 아동에게 성인기 발병 질환이나 비의료적 형질을 예측적으로 적용하는 것은 "아동의 열린 미래에 대한 권리" 관점에서 바람직하지 않습니다. 이런 이유로 APOE, FTO, MTHFR, Factor V Leiden 등 질병·대사 위험과 관련된 SNP는 처음부터 분석 대상에서 제외했고, 친족관계·조상 검증에서도 순수하게 통계적인 방법(멘델 오류율, 유전자형 일치율)만 사용했습니다. 또한 Child 2-Child 3의 높은 유사도는 "쌍둥이 가능성과 부합하는 패턴"이라는 수준까지만 서술했고, 확정적으로 단정하지 않았습니다.

REFERENCES

7. 참고 자료

- [KING — IBS0 기반 친족관계\(Relationship Inference\) 방법론](#)
- [PLINK 1.9 — --mendel 트리오 멘델 오류 QC 문서](#)
- [ACTN3 R577X 유전형과 근섬유 유형 \(Genetic Lifehacks\)](#)
- [TAS2R38 쓴맛 수용체와 장수 연구 \(Scientific Reports\)](#)
- [CYP1A2 카페인 대사 해설 \(Gene Food\)](#)
- [Rethinking the "Open Future" Argument — 아동 예측 유전자검사 윤리 논의 \(PMC\)](#)
- [폴리제닉 스코어\(PRS\)의 인구집단 간 이식성 원리·방법론 \(Nature Reviews Genetics\)](#)